强化学习作业/第8次/个人作业/TRPO三个等 式的证明

1 TRPO起点等式的证明


$$\eta(ilde{\pi}) = \eta(\pi) + E_{ au| ilde{\pi}}[\sum_{t=0}^{\infty} \gamma^t(A_{\pi}(s_t, a_t))]$$

。 证明过程

$$\begin{aligned} & \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} A_{j}(S_{t}, a_{t}) \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} (r(S_{t}) + |A| Y |V(S_{t+1}) - V(S_{t})| \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} r(S_{t}) + \sum_{t=0}^{\infty} Y^{t} (y |V(S_{t+1}) - V(S_{t})| \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} r(S_{t}) + \left(- V(S_{t}) \right) \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} r(S_{t}) + \left(- V(S_{t}) \right) \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} r(S_{t}) + \left(- V(S_{t}) \right) \right] \\ &= \mathcal{E}_{\tau \mid \widetilde{\lambda}} \left[\sum_{t=0}^{\infty} Y^{t} r(S_{t}) - V(S_{t}) \right] - \mathcal{E}_{S_{t}} \left[- V(S_{t}) \right] \end{aligned}$$

2 替代回报函数和原回报函数在 $heta= heta_{old}$ 处相等、一阶近似

 \circ 替代回报函数和原回报函数在策略 π_{old} 处一阶近似的证明



。 上图中红色一行推导的理解: 上一行表示对于 $V_{\pi_{\theta}}(s)$ 的梯度,可以转化成对策略梯度* $Q_{\pi_{\theta}}(s,a)$ +所有可能的下一状态的 $V_{\pi}(s')$ 的梯度*这一状态s'出现的概率,因此是一种迭代的计算方法,继续迭代下去,会遍历到所有可能的状态与行为;因此,在红色行中,计算**策略梯度*行为值函数**的期望: 首先对行为空间进行积分,之后对状态s进行积分;对状态s积分时,概率是从s经过任意步数转变为x的概率的和,因为是要计算准确的值函数梯度,必须要计算到结束。

3 TRPO优化目标的一阶近似、约束条件的二阶近似

• 对TRPO目标函数一阶逼近、对约束条件二阶逼近

。 KL散度非负(非负性证明见教材P155),在 $\theta=\theta_{old}$ 处,KL散度=0,所以 θ_{old} 是KL散度函数(θ)的一个极值点,因此KL散度函数一阶导数=0